

Nome dos integrantes:

Gabriel Veloso Barbosa - RA: 1990821

Gabriela dos Santos de Lima 2014108

Gustavo Lima dos Santos 1992035

Análise de Doença Cardíaca com Machine Learning

1. Introdução

Este trabalho tem o objetivo de analisar um conjunto de dados clínicos de pacientes para diagnóstico de doença cardíaca utilizando técnicas de Machine Learning.

Etapas:

Análise exploratória de dados (EDA)

Pré-processamento

Modelos Utilizados e Comparações

Comparação das métricas

Importância das Variáveis

Discussão

Conclusão

Avaliação e comparação de desempenho

2. Análise Exploratória dos Dados (EDA)

Inicialmente, foi feita a exploração do dataset para entender a distribuição dos dados e identificar padrões relevantes.


Este gráfico mostra que os dados foram balanceados entre pacientes saudáveis e com doença. Variáveis como idade, tipo de dor no peito e exames clínicos nos mostraram uma certa relação com a doença.

```
plt.title('Quantos pacientes temos no estudo?')
plt.xlabel('0 = Saudável | 1 = Doença Cardíaca')
plt.ylabel('Total de Pessoas')
plt.show()
```

/tmp/ipykernel_16526/761192085.py:2: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0

```
sns.countplot(data=df, x='target', palette=['#2ecc71', '#e74c3c'])
```




Estes dois gráficos nos mostram quantos pacientes têm ou não a doença, tendo a importância para entender o balanceamento do dataset. Histograma da idade por classe mostra uma relação entre idade e doença cardíaca, indicando que faixas etárias mais elevadas tendem a ter mais chances de ter a doença. Assim podendo ajudar a visualizar padrões de risco como mapa de calor, mostrando quais variáveis mais influenciam a doença.

```

sns.histplot(data=df, x='age', hue='target', kde=True, multiple="stack", palette='coolwarm')
plt.title('Distribuição de Idade por Doença Cardíaca')
plt.xlabel('Idade')
plt.ylabel('Frequência')
plt.show()


```




```

sns.heatmap(features_numericos_corr(), annot=True, cmap='coolwarm', cbar=True)
plt.title('O que influencia a doença?')
plt.show()


```



O gráfico por distribuição de gênero nos indica diferenças nas ocorrências da doença cardíaca entre homens e mulheres, indicando que a variável contribui para o processo de classificação.



Neste gráfico analisamos a idade, pressão arterial, colesterol, frequência cardíaca, e o oldpeak. Identificamos que no gráfico de Outliers, existem alguns valores que são extremos, sendo eles: colesterol e pressão arterial.



3. Pré-processamento dos Dados

Antes do treinamento dos modelos, os dados passaram por tratamentos sendo eles:

Valores ausentes: preenchidos com mediana (numéricos) e moda (categóricos)

Codificação: variáveis categóricas convertidas para números

Normalização: aplicada com StandardScaler

Divisão dos dados:

Treino: 588 amostras

Validação: 148 amostras

Teste: 184 amostrar

4. Modelos Utilizados e Comparações:

Foram comparados três algoritmos de classificação:

Regressão Logística


KNN (K-Nearest Neighbors)

SVM (Support Vector Machine)


Os modelos foram avaliados em:

Acurácia - Precisão - Recall - F1-Score -AUC-ROC


As matrizes de confusão basicamente nos ajudaram a analisar os acertos, falso positivos e falso negativos de cada modelo.



O gráfico de curvas ROC compara o desempenho dos modelos, mostrando uma maior capacidade de desempenho.



5. Comparação das métricas



→ Melhor Recall: SVC (0.9020)
 → Melhor F1-Score: SVC (0.8638)
 → Melhor AUC-ROC: SVC (0.9167)

Em contexto clínico, priorizamos RECALL para minimizar Falsos Negativos.
 O modelo recomendado é: SVC


Este gráfico compara acurácia, recall, F1 etc, ele ajuda a escolher o melhor modelo.

Melhor Recall: SVC(0.9020)
 Melhor F1-Score: SVC (0.8638)
 Melhor AUC-ROC: SVC (0.9167)

Escolha do Melhor Modelo: Escolhemos o Recall, pois, em um contexto clínico, errar um doente (falso negativo) é mais grave, sendo melhor identificar mais possíveis doentes, mesmo com alguns falsos positivos

O modelo escolhido foi o que melhor se enquadrava para um diagnóstico cardíaco.

6. Importância das Variáveis



Este gráfico mostra quais as variáveis mais influenciam o modelo, tendo principais fatores identificados como: Sex (Sexo) - Exange - Tipo de dor no peito (cp) - fbs - cp - Oldpeak - Talassemia (thal)

Melhorias Do notebook e relatório

Tópico	P1	P2	Status
Data Leakage	Existia	Corrigido	Aprovada ▾
Análise por sexo	Não	Adicionado	Aprovada ▾
Outliers	Não	Adicionado	Aprovada ▾
Relatório	Não	Atualizado	Aprovada ▾
Consistência Notebook x Relatório	Divergências	Corrigido	Aprovada ▾

7. Discussão

Os resultados são coerentes com a leitura médica:

Idade aumentando o risco cardíaco

Dor no peito sendo um indicativo

Exames clínicos sendo determinantes

8. Conclusão

O trabalho demonstra que é possível verificar que a aplicação de técnicas de Machine Learning pode ser eficaz na identificação de doenças cardíacas. A etapa de análise exploratória (EDA) permitiu entender como o comportamento das variáveis e a sua relação com o diagnóstico, tendo alguns fatores, como idade, tipo de dor no peito e resultados de exames clínicos.

O pré-processamento dos dados foi responsável por garantir a qualidade das informações utilizadas nestes mesmos modelos, conseguindo contribuir para um melhor desempenho das técnicas aplicadas. Entre os modelos testados, a escolha baseada no recall mostrou que adequada ao contexto médico, priorizando a identificação de pacientes doentes, reduz o risco de falsos negativos.

Os modelos de classificação podem servir como ferramentas de apoio a decisão médica, auxiliando na triagem e também no diagnóstico precoce das doenças cardíacas.

Após implementações no notebook e relatório, corrigimos o data leakage e adicionamos distribuições na EDA, resultando em um modelo mais confiável e real. Podendo ajudar como apoio nas decisões médicas

No primeiro relatório e no notebook, como não tínhamos consistência dos dados, acabou que o Logistic Regression tinha gerado dados mais precisos, mas ao corrigir o notebook, constatou-se que o SVC ganhou por ser mais preciso.

Principais pontos:

- Dados bem tratados melhoram o desempenho
- O Recall é essencial em problemas médicos
- O SVC mostrou que pode ser interpretável e eficiente.
- A correção do data leakage tornou a avaliação mais robusta e organizada.